




سؤال ۱.

• (آ) همان‌طور که در کلاس درس و اسلایدها^۱ نیز اشاره شد، SSE معیار خوبی اندازه‌گیری خطا برای دسته‌بندی نیست؛ زیرا حتی برای داده‌هایی که درست دسته‌بندی شده‌اند اما فاصله‌ی زیادی با خط دارند، جریمه‌ی^۲ سنگینی برای آن‌ها نیز در نظر می‌گیرد و معیار نزدیکی به دسته‌بند^۳ برای آن اهمیت دارد. در حالی که ممکن است دسته‌بندی داده‌ها به خوبی انجام گرفته باشد و خطای SSE بزرگ باشد.

• (ب)



شکل ۱: مقایسه‌ی عمل‌کرد perceptron و شمردن داده‌های misclassified

با توجه به شکل،^۴ استفاده از روش perceptron criterion به ما این امکان را می‌دهد که به یک فضای محدب،^۵ و پیوسته برسیم. به همین خاطر از روش‌های iterative مانند gradient descent برای رسیدن به جواب بهینه می‌توان استفاده کرد. این در حالی است که همان‌طور که مشاهده می‌شود، در روش شمردن تعداد داده‌های اشتباه دسته‌بندی‌شده، به شکلی می‌رسیم که مشتق^۶ آن، صفر است و نمی‌توان از روش‌های iterative استفاده کرد.

^۱ اسلاید ۷، صفحه‌ی ۲۱.

^۲ penalty

^۳ classifier

^۴ ر.ک. اسلاید ۷، صفحه‌ی ۲۴.

^۵ convex

^۶ gradient

- (پ) در حالت کلی سه رویکرد برای دسته‌بندی وجود دارد که دو نوع آن احتمالاتی و یکی نوع آن discriminant است. تابع خطای logistic regression از نوع احتمالاتی و perceptron از نوع discriminant است. مزایای logistic regression:

- در مدل احتمالاتی، استنتاج^۷ از تصمیم‌گیری^۸ جدا می‌شود.^۹
- از لحاظ محاسباتی کارا است.
- این امکان را به ما می‌دهد تا:
- * ریسک را حتی اگر ماتریس وزن‌دهی خطا^{۱۰} عوض شد، کمینه کنیم.
- * Reject option داشته باشیم.
- * unbalanced class priors داشته باشیم.
- * مدل‌ها را ترکیب کنیم.

- (ت) به دلیل غیرخطی بودن تابع sigmoid، برای logistic regression راه‌حل بسته‌ای^{۱۱} وجود ندارد. روش IRLS^{۱۲} می‌تواند سریع‌تر باشد. برای مثال اگر تابع $\log - likelihood$ تقریباً درجه دو باشد، ممکن است فقط در چند مرحله به نقطه‌ی بهینه همگرا شود. به همین علت در کتاب Bishop نوشته شده است که: «اگر چه چنین روشی ممکن است منطقی به نظر برسد اما در حقیقت یک الگوریتم ضعیف است.»^{۱۳}
- با توجه به دلایل مذکور، احتمال پیدا کردن ججاب بهینه، در روش IRLS با تعداد عملیات کمتر، بیش‌تر است.^{۱۴}

- (ث) Probit regression نسبت به داده‌های پرت حساس‌تر است؛ زیرا اگر انتهای هر کدام از تابع‌ها را بررسی کنیم، به نتیجه‌ی زیر می‌رسیم:

$$\begin{cases} \text{logistic regression tails} & \approx e^{-x} \\ \text{probit regression} & \approx e^{-x^2} \end{cases}$$

- به همین دلیل اگر داده‌ی پرتی به تابع probit regression داده شود، وزن بیش‌تری به آن می‌دهد؛ بنابراین به داده‌های پرت نیز حساس‌تر است.

^۷ inference
^۸ decision
^۹ در استنتاج به دنبال تخمین $p(t|x)$ هستیم اما در تصمیم‌گیری برای x داده شده به دنبال t بهینه هستیم.
^{۱۰} loss matrix
^{۱۱} closed form solution
^{۱۲} Iterative Reweighted Logistic Regression
^{۱۳} سوال پرسیده شده در stackexchange
^{۱۴} اسلاید ۷، صفحه‌ی ۶۰.

سؤال ٢.

سؤال ٣.

سؤال ٤.

سؤال ٥.

سؤال ٦.

سؤال ٧.

سؤال ٨.