




سؤال ۱. ماشین بردار پشتیبان

• الف)

- یک) خیر. اگر $C \rightarrow \infty$ آن‌گاه برای مجموعه داده‌هایی که به صورت خطی جداپذیر باشند، این اتفاق رخ خواهد داد.^۱
- دو) همان‌طور که در شکل زیر مشخص است، حالات مختلف ممکن برای ϵ عبارتند از:
 - * $\epsilon > 1$: داده به‌طور اشتباه دسته‌بندی شده است.
 - * $\epsilon = 1$: یعنی داده روی مرز تصمیم^۲ قرار دارد.
 - * $0 < \epsilon < 1$: داده درست دسته‌بندی شده است اما در margin قرار دارد.
 - * $\epsilon = 0$: داده درست دسته‌بندی شده است اما ممکن است روی margin یا بیرون آن باشد.



شکل ۱: توصیف معنایی حالات مختلف ϵ

- سه) حل مسئله با M متغیر به طور کلی پیچیدگی از $O(M^3)$ دارد. در دوگان مسئله‌ی بهینه‌سازی را می‌خواهیم حل کنیم که به جای M متغیر، N متغیر دارد. برای تعداد ثابت توابع basis چون که $M < N$ است، استفاده از روش دوگان به دلیل سرعت کمتر خوب نیست.
- استفاده روش دوگان به ما امکان استفاده از هسته‌ها را می‌دهد و می‌توانیم دسته‌بند حاشیه بیشینه^۳ را که ابعاد ویژگی‌های آن بیش‌تر از تعداد نقاط است پیدا کنیم و بسیار کارا است و حتی جواب‌گوی مواقعی که تعداد ویژگی‌ها به بی‌نهایت میل می‌کند می‌باشد.^۴


^۱ ر.ک. صفحه ۳۳۲ کتاب

^۲ decision boundary


^۳ maximum margin classifier

^۴ ر.ک صفحه ۳۲۹ کتاب


- چهار)



شکل ۲: نمودار آبی: ماشین بردار پشتیبان نرم، نمودار قرمز: logistic regression، نمودار مشکی: خطای دسته‌بندی و نمودار سبز: مربع خطاها



شکل ۳: ماشین بردار پشتیبان سخت



شکل ۴: perceptron

- (ب) در این رابطه حساسیت به داده‌های نویز بیشتر می‌شود؛ زیرا در مدل هدف این است که مجموع مجذورات را کمینه کنیم، بنابراین داده‌های کم‌تری باید به‌طور اشتباه دسته‌بندی شوند و داده‌های نویز اثر و وزن زیادی نسبت به حالت عادی تابع هزینه دارند.

$$L(w, w_0, \Sigma, \alpha, \beta) = \frac{1}{2} \|w\|^2 + \sum_{n=1}^N (\alpha_n) (1 - \Sigma_n - y^{(n)} (w^T x^{(n)} + w_0) + c \sum_{n=1}^N \Sigma_n^2 - \sum_{n=1}^N \beta_n \Sigma_n$$

• (پ)

– (یک)

$$\tilde{L}(a) = \sum_{n=1}^N a_n - \frac{1}{2} \sum_{n=1}^N \sum_{m=1}^N a_n a_m t_n t_m k(x_n m x_m)$$


از آن جایی که تعداد داده‌ها ۵ است، بنابراین: ۵

$$\tilde{L}(a) = \sum_{n=1}^5 a_n - \frac{1}{2} \sum_{n=1}^5 \sum_{m=1}^5 a_n a_m t_n t_m k(x_n m x_m)$$

$$\tilde{L}(a) = \sum_{n=1}^5 a_n - \frac{1}{2} (a_1^2 - 4a_1 a_4 - 4a_1 a_3 - 6a_1 a_5 + a_2^2 - 2a_2 a_3 - 4a_2 a_4 + 5a_3^2 - 2a_2 a_5 + 12a_3 a_4 + 14a_3 a_5 + 8a_4^2 + 16a_4 a_5 + 10a_5^2)$$

$$a_n \geq 0 \implies \sum_{n=1}^N a_n t_n = 0 \implies a_1 + a_2 - a_3 - a_4 - a_5 = 0$$

– (دو) چون نقطه‌های ۴ و ۵ نمی‌توانند بردار پشتیبان باشند، داریم:



$$a_4 = a_5 = 0 \implies a_1 + a_2 - a_3 = 0 \implies a_1 + a_2 = a_3$$

– (سه) با جای‌گذاری نتیجه‌ی بالا در معادله‌ی قسمت «۱» داریم:

$$\tilde{L}(a) = a_1 + a_2 + a_3 - \frac{1}{2} (a_1^2 + a_2^2 + 5a_3^2 - 4a_1 a_3 - 2a_2 a_3)$$

– (چهار) برای حل مسئله‌ی بهینه‌سازی باید لاگرانژ تابع را برابر با صفر قرار دهیم.

$$\nabla \tilde{L}(a) = 0 \implies \begin{cases} 1 - \frac{1}{2}(2a_1 - 4a_3) = 0 & \text{with respect to } a_1 \\ 1 - \frac{1}{2}(2a_2 - 2a_3) = 0 & \text{with respect to } a_2 \\ 1 - \frac{1}{2}(-4a_1 - 2a_2 + 10a_3) = 0 & \text{with respect to } a_3 \end{cases}$$

از قسمت قبلی دریافتیم که $a_1 + a_2 = a_3$. حال با حذف a_3 از دو معادله داریم:

$$a_1 - a_2 = a_3$$

با جای‌گذاری این نتایج در معادلات بالا، به دست می‌آوریم:

$$a_1 = a_3 = \frac{1}{3}, a_2 = 0$$

– پنج)

$$y(x) = wx + b \implies w = \frac{1}{3}(x_1 - x_3) = \left(-\frac{1}{3}, -\frac{1}{3}\right), b = \frac{2}{3} \implies y(x) = \left(-\frac{1}{3}, -\frac{1}{3}\right)x + \frac{2}{3}$$

سؤال ۲. هسته

• الف)

– یک) از آنجایی که می‌دانیم $k_1(x, x')$ و $k_2(x, x')$ دو هسته‌ی معتبر هستند؛ بنابراین ماتریس هسته K_1 و K_2 هر دو مثبت نیمه‌معین هستند. پس اگر فرض کنیم که ورودی‌های x و x' هر دو، دو بعدی باشند، داریم:

$$\begin{aligned} k_3(x, x') &= (x^T x')^2 = (x_1 x'_1 + x_2 x'_2)^2 = x_1^2 x_1'^2 + 2x_1 x'_1 x_2 x'_2 + x_2^2 x_2'^2 \\ \Rightarrow k_3(x, x') &= (x_1^2, \sqrt{2}x_1 x_2, x_2^2)(x_1'^2, \sqrt{2}x'_1 x'_2, x_2'^2) = \phi(x)^T \phi(x') \end{aligned}$$

با توجه به نتیجه‌ی بالا داریم:

$$k_3 = k_1 + k_2$$

پس k_3 نیز مثبت نیمه‌معین بوده و ثابت شد که معتبر نیز هست.

– دو) با فرض این‌که تابع نگاشت هسته‌ی k_1 ، $\phi^{(1)}(x)$ با ابعاد M و تابع نگاشت هسته‌ی k_2 ، $\phi^{(2)}(x)$ با ابعاد N است، داریم:

$$\begin{aligned} k_4(x, x') &= k_1(x, x')k_2(x, x') = \phi^{(1)}(x)^T \phi^{(1)}(x') \phi^{(2)}(x)^T \phi^{(2)}(x') = \sum_{i=1}^M \phi_i^{(1)}(x) \phi_i^{(1)}(x') \sum_{j=1}^N \phi_j^{(2)}(x) \phi_j^{(2)}(x') \\ \Rightarrow k_4(x, x') &= \sum_{i=1}^M \sum_{j=1}^N [\phi_i^{(1)}(x) \phi_j^{(2)}(x)] [\phi_i^{(1)}(x') \phi_j^{(2)}(x')] = \sum_{k=1}^M N \phi_k(x) \phi_k(x') = \phi(x)^T \phi(x') \end{aligned}$$

که در آن $\phi_i^{(1)}(x)$ ، عنصر i ام $\phi^{(1)}(x)$ و $\phi_j^{(2)}(x)$ عنصر j ام $\phi^{(2)}(x)$ است.

– سه)

از آنجایی که k_1 یک هسته‌ی معتبر است، بنابراین آن را به صورت $k_1(x, x') = \phi(x)^T \phi(x')$ می‌توان نوشت. پس:

$$k_5(x, x') = a k_1(x, x') = [\sqrt{a} \phi(x)]^T [\sqrt{a} \phi(x')]$$

که با توجه به فرض $a \geq 0$ ثابت می‌شود.

– چهار) اگر بسط تیلور را بنویسیم داریم:

$$k_6(x, x') = a_n k_1(x, x')^n + a_{n-1} k_1(x, x')^{n-1} + \dots + a_1 k_1(x, x') + a_0$$

حال با استفاده از نتایج سه قسمت قبل و با توجه به این‌که همه‌ی ضرایب بسط تیلور مثبت است، پس این هسته نیز یک هسته‌ی معتبر است.

• ب) با توجه به این‌که تابع هسته را می‌توان آن را به شکل ضرب داخلی در فضای ویژگی نوشت، پس هسته‌ی معتبر است. برای اثبات باید به رابطه‌ی $k(A, B) = 2^{|A \cap B|} = \phi(A)^T \phi(B)$ برسیم.

اگر

$$\phi_U(X) = \begin{cases} 1 & \text{if } U \subseteq X \\ 0 & \text{otherwise} \end{cases}$$

باشد، داریم:

$$\phi(A)^T \phi(B) = \sum_{U \subseteq A \cap B} \phi_U(A) \phi_U(B)$$

با استفاده از سیگما (جمع کردن) در رابطه‌ی بالا، همه‌ی زیرمجموعه‌های ممکن $|A \cap B|$ را اگر و تنها اگر هم زیرمجموعه‌ی A و B باشد (مقدار برابر با ۱) داریم. با این کار تعداد زیرمجموعه‌های اشتراک A و B در فضای S را محاسبه کرده‌ایم. علاوه‌براین هم A و هم B به عنوان زیرمجموعه‌ی فضای S معرفی شده‌اند، بنابراین:

$$\phi(A)^T \phi(B) = 2^{|A \cap B|}$$

• پ)

یک -)

$$k(x, x') = (x^T \cdot x' + c)^2 = k\left(\begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_d \end{pmatrix}, \begin{pmatrix} x'_1 \\ x'_2 \\ \vdots \\ x'_d \end{pmatrix}\right) = (c + x_1 x'_1 + x_2 x'_2 + \dots + x_d x'_d)^2$$

$$\Rightarrow k(x, x') = c^2 \sum_{i=1}^d x_i^2 x_i'^2 + \sum_{i=1}^d 2c x_i x_i' + \sum_{i=1}^{d-1} \sum_{j=i+1}^d 2x_i x_i' x_j x_j'$$

$$\Rightarrow k(x, x') = \begin{pmatrix} c & x_1^2, \dots, x_d^2, & \dots & \sqrt{2c}x_d \end{pmatrix} \begin{pmatrix} x'_1, \dots, x'_d \\ \vdots \\ \sqrt{2c}x'_d \end{pmatrix}$$

$$\Rightarrow k(x, x') = \phi(x)^T \phi(x')$$

– دو) اگر $c = 0$ باشد، آنگاه فضای تبدیل $d + 1$ بعد کاهش می‌یابد؛ زیرا تعداد جملاتی که در آن c ضرب شده است، $d + 1$ است که با صفر شدن آن حذف می‌شوند.

– سه)

$$k(x, x') = (x^T \cdot x' + c)^M$$

با توجه به توضیحاتی که در این لینک داده شده است، تعداد جملات برابر با:

$$\# \text{ of expressions} = \binom{M + d + 1 - 1}{d + 1 - 1} = \binom{M + d}{d}$$

سؤال ۳. درخت تصمیم

• الف)

$$Gain(y, x_d) = \sum_i \sum_j p(y = j, x_d = i) \log \frac{p(x_d = i)p(y = j)}{p(y = j, x_d = i)}$$

با توجه به استقلال x_d و y داریم:

$$p(y, x_d) = p(y)p(x_d)$$

$$\Rightarrow Gain(y, x_d) = \sum_i \sum_j p(y = j, x_d = i) \log \frac{p(x_d = i)p(y = j)}{p(y = j)p(x_d = i)} = \sum_i \sum_j p(y = j, x_d = i) \log(1) = 0$$

• ب) اگر ملاک ساختن درخت تصمیم‌گیری را براساس مقدار information gain قرار دهیم، به دلیل استقلال و یکتا بودن آن (همانند قسمت قبل)، مقدار gain برابر با صفر می‌شود. پس به عنوان ریشه‌ی درخت قرار نمی‌گیرد. حال اگر فرض کنیم این ویژگی به عنوان ریشه انتخاب شده، overfitting به دلیل یکتایی ویژگی‌ها حتمی خواهد بود. برای جلوگیری از overfitting عمدتاً دو راه‌کار وجود دارد:

۱. زودتر متوقف کردن درخت برای این‌که به نقطه‌ای نرسد که همه‌ی داده‌های آموزش را به‌طور کامل و عالی یاد گرفته باشد.

۲. استفاده از تکنیک post-pruning. به روی‌کردی می‌گویند که داده‌ی آموزش و اعتبارسنجی وجود دارد که برای هرس کردن از آن استفاده می‌شود.

• پ)

– یک)

– دو)

– سه)

سؤال ۴. یادگیری جمعی

• الف) نامساوی Jensen:

$$f(\sum_{i=1}^M \lambda_i x_i) \leq \sum_{i=1}^M \lambda_i f(x_i)$$

همان‌طور که در صورت سوال گفته شده است برای E_{avg} داریم:

$$E_{avg} = \frac{1}{M} \sum_{i=1}^M E_x[(h_m(x) - h(x))^2]$$

حال اگر $\frac{1}{M}$ را به درون سیگما ببریم، داریم:

$$E_{avg} = E_x[\sum_{m=1}^M \frac{1}{M} (h_m(x) - h(x))^2]$$

حال با توجه به نامساوی Jensen و محدب بودن تابع داریم:

$$(\sum_{m=1}^M \frac{1}{M} (h_m(x) - h(x))^2) \leq \sum_{m=1}^M \frac{1}{M} (h_m(x) - h(x))^2$$

$$\implies E_{com} \leq E_{avg}$$

• ب)

$$E_{avg} = \frac{1}{M} \sum_{m=1}^M E_x[(h_m(x) - h(x))^2]$$

$$E_{com} = E_x[(\frac{1}{M} \sum_{m=1}^M h_m(x) - h(x))^2] = E_x[(\frac{1}{M} \sum_{m=1}^M h_m(x) - h(x))(\frac{1}{M} \sum_{l=1}^M h_l(x) - h(x))]$$

حال اگر یکی از عامل‌های $\frac{1}{M}$ را به دلیل ثابت بودن از داخل امید ریاضی بیرون بیاوریم، به دلیل فرضیات یعنی

$$\forall m \neq l \ E[(h_m(x) - h(x))(h_l(x) - h(x))] = 0$$

داریم:

$$E_{com} = \frac{1}{M} (\frac{1}{M} \sum_{m=1}^M E_x[(h_m(x) - h(x))^2]) = \frac{1}{M} E_{avg}$$

سؤال ۵. Adaboost

• الف) فرض خلف: $h_t = h_{t+1}$

$$\epsilon_t = \frac{\sum_{i=1}^N w_t^{(i)} I(y^{(i)} \neq h_t(x^{(i)}))}{\sum_{i=1}^N w_t^{(i)}} = \frac{\sum_{i=1}^N w_t^{(i)} I(y^{(i)} \neq h_t(x^{(i)}))}{\sum_{i=1}^N w_t^{(i)} I(y^{(i)} \neq h_t(x^{(i)})) + \sum_{i=1}^N w_t^{(i)} I(y^{(i)} = h_t(x^{(i)}))} < \frac{1}{2}$$

با توجه به نحوه عمل کرد الگوریتم Adaboost و فرض اولیه داریم:

$$\begin{aligned} \epsilon_{t+1} &= \frac{\sum_{i=1}^N w_t^{(i)} I(y^{(i)} \neq h_t(x^{(i)}))}{\sum_{i=1}^N w_t^{(i)} I(y^{(i)} \neq h_t(x^{(i)})) + \sum_{i=1}^N w_t^{(i)} I(y^{(i)} = h_t(x^{(i)}))} = \frac{\frac{1-\epsilon_t}{\epsilon_t} \sum_{i=1}^N w_t^{(i)} I(y^{(i)} \neq h_t(x^{(i)}))}{\frac{1-\epsilon_t}{\epsilon_t} \sum_{i=1}^N w_t^{(i)} I(y^{(i)} \neq h_t(x^{(i)})) + \sum_{i=1}^N w_t^{(i)} I(y^{(i)} = h_t(x^{(i)}))} \\ \Rightarrow \epsilon_{t+1} &= \frac{\sum_{i=1}^N w_t^{(i)} I(y^{(i)} = h_t(x^{(i)}))}{2 \sum_{i=1}^N w_t^{(i)} I(y^{(i)} = h_t(x^{(i)}))} = \frac{1}{2} \end{aligned}$$

که خلاف فرض است و حکم ثابت می شود.

• ب) خطای تابع نمایی به صورت $E = \sum_{n=1}^N e^{-t_n f_m(x_n)}$ است که f_m به شکل $f_m(x) = \frac{1}{2} \sum_{l=1}^m \alpha_l y_l(x)$ تعریف می شود و $t_n \in \{-1, 1\}$ می باشد. به جای کمینه کردن تابع خطای کلی، می توان با توجه به α_m و $y_m(x)$ این کار را انجام داد:

$$E = \sum_{n=1}^N e^{-t_n f_{m-1}(x_n) - \frac{1}{2} t_n \alpha_m y_m(x_n)} = \sum_{n=1}^N w_n^{(m)} e^{-\frac{1}{2} t_n \alpha_m y_m(x_n)}$$

که در آن $w_n^{(m)} = e^{-t_n f_{m-1}(x_n)}$ بوده و آن را می توان ثابت در نظر گرفت زیرا تنها α_m و $y_m(x)$ را بهبود می دهیم. اگر τ_m را داده هایی که درست دسته بندی شده اند و M_m را داده هایی بگیریم که غلط دسته بندی شده اند، بگیریم داریم:

$$\begin{aligned} E &= e^{-\frac{\alpha_m}{2} \sum_{n \in \tau_m} w_n^{(m)}} + e^{\frac{\alpha_m}{2} \sum_{n \in M_m} w_n^{(m)}} \\ \Rightarrow E &= (e^{\frac{\alpha_m}{2}} - e^{-\frac{\alpha_m}{2}}) \sum_{n=1}^N w_n^{(m)} I(y_m(x_n) \neq t_n) + e^{-\frac{\alpha_m}{2} \sum_{n=1}^N w_n^{(m)}} \end{aligned}$$

حال اگر بخواهیم با توجه به y_m کمینه کنیم، عبارت دوم ثابت خواهد بود بنابراین با عنایت به نتایجی که معادلات بالا به دست آمد داریم:

$$w_n^{(m+1)} = w_n^{(m)} e^{-\frac{1}{2} t_n \alpha_m y_m(x_n)}$$

با توجه به $1 - 2I(y_m(x_n) \neq t_n)$ می توان عبارت به دست آوردن وزن جدید را به صورت زیر بازنویسی کرد:

$$w_n^{(m+1)} = w_n^{(m)} e^{-\frac{\alpha_m}{2}} e^{\alpha_m I(y_m(x_n) \neq t_n)}$$

به دلیل استقلال $e^{-\frac{\alpha_m}{2}}$ از n چون همه ی عبارات چنین عامل مشترکی دارند می توان آن را در نظر نگرفت.